

Davin Edbert Santoso Halim / 2602067086

## NOMER 3.a

a. [LO 1, LO 2, LO 3, 5 poin] **Jelaskan cara kerja dari arsitektur tersebut yang dideskripsikan dalam gambar di bawah ini:**

### 1. Generator:

- Generator adalah bagian neural network yang membuat data palsu yang menyerupai data asli.
- Input dari generator adalah random noise (biasanya random vektor).
- Generator belajar untuk mengubah noise acak tersebut menjadi gambar yang terlihat nyata. Dalam gambar, ini diwakili oleh blok biru di sisi kiri.

### 2. Discriminator:

- Discriminator adalah neural network untuk membedakan antara data asli (dari set pelatihan) dan data palsu (dari generator).
- Discriminator menerima gambar dan menentukan apakah gambar tersebut asli atau palsu. (Dalam gambar, ini diwakili oleh blok merah di sisi kanan.)

### 3. Training Set:

- Training set terdiri dari data asli yang digunakan untuk melatih discriminator. Data ini memberikan contoh nyata yang harus ditiru oleh generator. (Dalam gambar, ini diwakili oleh tumpukan gambar di atas.)

### 4. Proses Training:

- Generator dan discriminator dilatih secara bersamaan dalam sebuah proses adversarial (berlawanan).
- Langkah-langkahnya adalah sebagai berikut:
  - Generator menghasilkan gambar palsu dari random noise.
  - Gambar palsu ini, bersama dengan gambar asli dari training set, diberikan kepada discriminator.
  - Discriminator mencoba membedakan antara gambar asli dan gambar palsu. Generator diperbarui berdasarkan seberapa baik gambar palsu yang dihasilkan bisa menipu discriminator.
  - Discriminator diperbarui berdasarkan seberapa baik ia dapat membedakan gambar asli dari gambar palsu.

## 5. Tujuan Akhir:

- Generator ingin membuat gambar yang begitu nyata sehingga discriminator tidak bisa membedakannya dari gambar asli.
- Discriminator ingin semakin pintar dalam membedakan gambar asli dan gambar palsu.

Dalam proses ini, generator dan discriminator saling berkompetisi, yang pada akhirnya meningkatkan kemampuan keduanya: generator menjadi lebih baik dalam menghasilkan gambar realistis, dan discriminator menjadi lebih baik dalam mendeteksi gambar palsu.

## ✓ 3B

```
import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from tensorflow.keras import layers
from scipy.linalg import sqrtm
from tensorflow.keras.applications.inception_v3 import InceptionV3, preprocess_input

from tensorflow.keras.datasets import fashion_mnist
(train_images, train_labels), (test_images, test_labels) = fashion_mnist.load_data()

class_names = ['T-shirt/top', 'Trouser', 'Pullover', 'Dress', 'Coat',
               'Sandal', 'Shirt', 'Sneaker', 'Bag', 'Ankle boot']

plt.figure(figsize=(10, 17))
num_images_per_class = 5 # Jumlah gambar per kelas
for class_id in range(10):
    class_indices = np.where(train_labels == class_id)[0]
    for i in range(num_images_per_class):
        plt.subplot(10, num_images_per_class, class_id * num_images_per_class + i + 1)
        plt.imshow(train_images[class_indices[i]], cmap='gray')
        plt.title(class_names[class_id])
        plt.axis('off')

plt.show()
```





```
print(f'Jumlah train img: {train_images.shape[0]}')
print(f'Jumlah test img: {test_images.shape[0]}')
```

```
⇒ Jumlah train img: 60000
   Jumlah test img: 10000
```

```
# Mengambil hanya kelas T-shirt/top (0) dan Trouser (1)
selected_train_indices = np.where((train_labels == 0) | (train_labels == 1))
selected_test_indices = np.where((test_labels == 0) | (test_labels == 1))
```

```
train_images_selected = train_images[selected_train_indices]
train_labels_selected = train_labels[selected_train_indices]
test_images_selected = test_images[selected_test_indices]
test_labels_selected = test_labels[selected_test_indices]
```

```
print(f"Train images shape (selected): {train_images_selected.shape}")
print(f"Train labels shape (selected): {train_labels_selected.shape}")
print(f"Test images shape (selected): {test_images_selected.shape}")
print(f"Test labels shape (selected): {test_labels_selected.shape}")
```

```
⇒ Train images shape (selected): (12000, 28, 28)
   Train labels shape (selected): (12000,)
   Test images shape (selected): (2000, 28, 28)
   Test labels shape (selected): (2000,)
```

```
print(f'Jumlah train img: {train_images_selected.shape[0]}')
print(f'Jumlah test img: {test_images_selected.shape[0]}')
```

```
⇒ Jumlah train img: 12000
   Jumlah test img: 2000
```

```
# Mengubah label menjadi teks
label_names = {0: 'T-shirt/top', 1: 'Trouser'}
train_labels_selected_text = np.vectorize(label_names.get)(train_labels_selected)
test_labels_selected_text = np.vectorize(label_names.get)(test_labels_selected)


# Menampilkan contoh data
plt.figure(figsize=(10, 5))
for i in range(10):
    plt.subplot(2, 5, i + 1)
    plt.imshow(train_images_selected[i], cmap='gray')
    plt.title(f'Label: {train_labels_selected_text[i]}')
    plt.axis('off')
plt.show()
```




Label: T-shirt/top




Label: T-shirt/top




Label: T-shirt/top



Label: T-shirt/top




Label: Trouser



Label: T-shirt/top



Label: Trouser




Label: T-shirt/top



Label: T-shirt/top



Label: Trouser



```
train_images_selected = train_images_selected.astype('float32') / 255.0
test_images_selected = test_images_selected.astype('float32') / 255.0
```

```
train_images_selected = np.expand_dims(train_images_selected, -1)
test_images_selected = np.expand_dims(test_images_selected, -1)
```

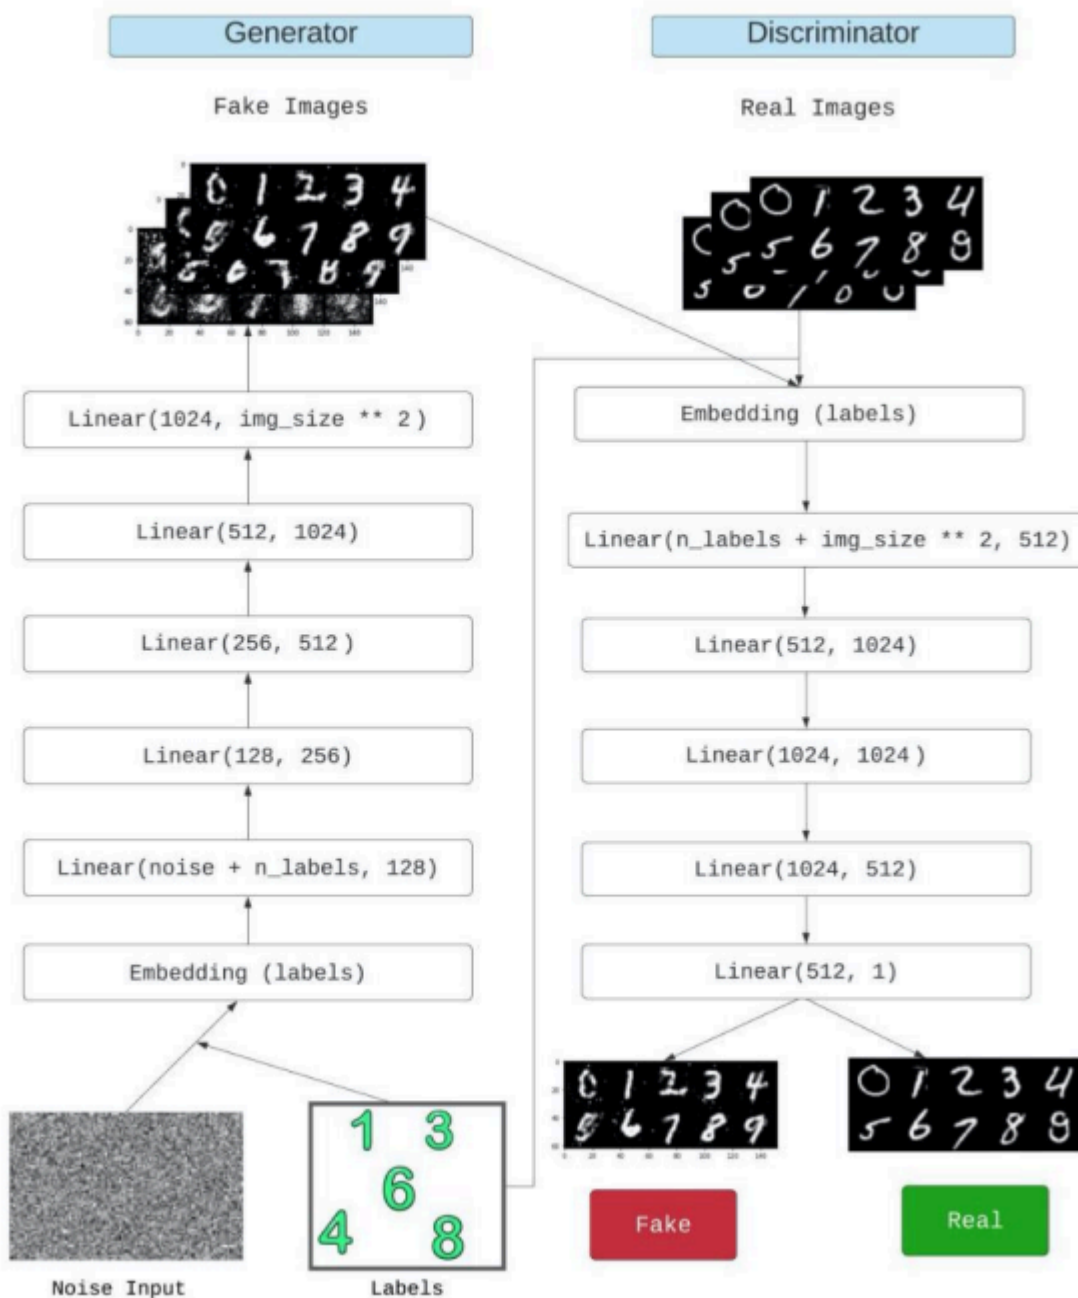
### Normalisasi Data:

- Tujuan: Mengubah tipe data gambar menjadi float32 dan menormalisasi nilai piksel dari rentang [0, 255] menjadi [0, 1].
- Manfaat: Normalisasi penting untuk stabilitas pelatihan GAN karena jaringan neural cenderung berperforma lebih baik dengan input yang memiliki skala nilai yang lebih kecil dan seragam.

### Penambahan Dimensi:

- Tujuan: Menambahkan satu dimensi tambahan ke array gambar, mengubah bentuknya dari (28, 28) menjadi (28, 28, 1).
- Manfaat: Banyak arsitektur jaringan convolutional, termasuk GAN, mengharapkan input dengan tiga dimensi (height, width, channels), bahkan jika gambar tersebut grayscale (memiliki satu channel). Ini memastikan data input sesuai dengan format yang diharapkan oleh model.

## ✓ MODELING



```
# Define the generator
def build_generator(latent_dim, num_classes):
    model = tf.keras.Sequential()

    model.add(layers.Input(shape=(latent_dim + num_classes,)))
    model.add(layers.Dense(128, activation='relu'))
    model.add(layers.Dense(256, activation='relu'))
    model.add(layers.Dense(512, activation='relu'))
    model.add(layers.Dense(1024, activation='relu'))
    model.add(layers.Dense(28 * 28, activation='tanh'))
    model.add(layers.Reshape((28, 28, 1)))

    return model
```

#### Generator:

1. Input: Noise dan label yang digabungkan.
2. Lapisan:
  - Dense Layers: 128, 256, 512, dan 1024 unit dengan aktivasi 'relu'.
  - Output Layer: Dense layer dengan ukuran 28x28 dan aktivasi 'tanh'.
  - Reshape Layer: Mengubah output menjadi bentuk gambar (28, 28, 1).
4. Output: Gambar palsu yang dihasilkan berdasarkan noise dan label.

#### Alasan Menggunakan ReLU:

1. Linearitas: ReLU adalah fungsi aktivasi linear untuk semua nilai positif, yang berarti outputnya proporsional terhadap inputnya (jika positif). Hal ini memudahkan jaringan neural untuk belajar dan mengoptimalkan bobot selama pelatihan.
2. Sederhana dan Efisien: ReLU adalah fungsi aktivasi yang sangat sederhana dan efisien. Ini hanya memerlukan operasi perbandingan sederhana untuk menghitung outputnya, yang membuat komputasi menjadi lebih cepat dibandingkan dengan fungsi aktivasi lain yang lebih kompleks.
3. Performa yang Lebih Baik dalam Praktek: ReLU telah terbukti bekerja sangat baik dalam praktek, terutama untuk jaringan deep learning. Banyak penelitian menunjukkan bahwa menggunakan ReLU dapat menghasilkan konvergensi yang lebih cepat dan performa yang lebih baik dibandingkan fungsi aktivasi lainnya.

```
# Define the discriminator
def build_discriminator(num_classes):
    img_size = 28 * 28
    model = tf.keras.Sequential()

    model.add(layers.Input(shape=(img_size + num_classes,)))
    model.add(layers.Dense(512, activation='leaky_relu'))
    model.add(layers.Dense(1024, activation='leaky_relu'))
    model.add(layers.Dense(1024, activation='leaky_relu'))
    model.add(layers.Dense(512, activation='leaky_relu'))
    model.add(layers.Dense(1, activation='sigmoid'))

    return model
```

Discriminator:

1. Input: Gambar (real atau palsu) dan label yang digabungkan.
2. Lapisan:
  - Dense Layers: 512 dan 1024 unit dengan aktivasi 'leaky\_relu'.
  - Output Layer: Dense layer dengan 1 unit dan aktivasi 'sigmoid'.
3. Output: Skor yang menunjukkan apakah gambar adalah asli atau palsu.

Alasan Menggunakan Leaky ReLU?

1. Fleksibilitas Linear: Linearitas Leaky ReLU dengan slope kecil untuk nilai negatif memberikan fleksibilitas tambahan dalam proses pembelajaran, memungkinkan jaringan untuk menangkap pola yang lebih kompleks dalam data.
2. Meningkatkan Gradien: Dalam jaringan deep learning, gradien yang lebih besar membantu dalam pembaruan bobot yang lebih efektif selama pelatihan. Leaky ReLU memastikan bahwa gradien tetap mengalir untuk nilai negatif, sehingga membantu dalam stabilitas dan kecepatan konvergensi model.
3. Efisiensi Komputasi: Seperti ReLU, Leaky ReLU adalah fungsi aktivasi yang sangat sederhana dan efisien secara komputasi. Ini hanya memerlukan operasi perbandingan dan perkalian sederhana, yang membuatnya cepat dihitung.

```
# Combine noise and labels
def combine_noise_and_labels(noise, labels, num_classes):
    label_embedding = tf.one_hot(labels, num_classes)
    return tf.concat([noise, label_embedding], axis=1)
```

Tujuan: Menggabungkan noise dengan embedding dari label untuk input ke generator.



```
# Combine images and labels
def combine_images_and_labels(images, labels, num_classes):
    label_embedding = tf.one_hot(labels, num_classes)
    images_flatten = tf.reshape(images, [images.shape[0], -1])
    return tf.concat([images_flatten, label_embedding], axis=1)
```

Tujuan: Menggabungkan gambar dengan embedding dari label untuk input ke discriminator.

```
latent_dim = 100
num_classes = 2
```

```
generator = build_generator(latent_dim, num_classes)
discriminator = build_discriminator(num_classes)
```

```
# Optimizers
optimizer_G = tf.keras.optimizers.Adam(learning_rate=0.0002, beta_1=0.5)
optimizer_D = tf.keras.optimizers.Adam(learning_rate=0.0002, beta_1=0.5)
```

Menggunakan Adam optimizer untuk generator (optimizer\_G) dan discriminator (optimizer\_D) dengan learning rate 0.0002 dan beta\_1 0.5.

```
# Loss function
cross_entropy = tf.keras.losses.BinaryCrossentropy()
```

Loss Function: Binary Crossentropy digunakan sebagai fungsi loss untuk mengukur perbedaan antara prediksi dan label nyata.

```

@tf.function
def train_step(real_images, real_labels):
    batch_size = tf.shape(real_images)[0]
    noise = tf.random.normal([batch_size, latent_dim])
    fake_labels = tf.random.uniform([batch_size], minval=0, maxval=num_classes, dtype=tf.int32)

    fake_images = generator(combine_noise_and_labels(noise, fake_labels, num_classes))

    combined_labels = tf.concat([tf.cast(real_labels, tf.int32), fake_labels], axis=0)
    combined_images = tf.concat([real_images, fake_images], axis=0)

    # Combine images and labels for discriminator
    real_images_with_labels = combine_images_and_labels(real_images, tf.cast(real_labels, tf.int32))
    fake_images_with_labels = combine_images_and_labels(fake_images, fake_labels, num_classes)
    combined_images_with_labels = tf.concat([real_images_with_labels, fake_images_with_labels], axis=0)

    # Discriminator training
    with tf.GradientTape() as tape:
        real_output = discriminator(real_images_with_labels, training=True)
        fake_output = discriminator(fake_images_with_labels, training=True)

        d_loss_real = cross_entropy(tf.ones_like(real_output), real_output)
        d_loss_fake = cross_entropy(tf.zeros_like(fake_output), fake_output)
        d_loss = d_loss_real + d_loss_fake

    grads = tape.gradient(d_loss, discriminator.trainable_variables)
    optimizer_D.apply_gradients(zip(grads, discriminator.trainable_variables))

    # Generator training
    noise = tf.random.normal([batch_size, latent_dim])
    misleading_labels = tf.ones([batch_size, 1])

    with tf.GradientTape() as tape:
        fake_images = generator(combine_noise_and_labels(noise, fake_labels, num_classes))
        fake_output = discriminator(combine_images_and_labels(fake_images, fake_labels, num_classes), training=True)

        g_loss = cross_entropy(misleading_labels, fake_output)

    grads = tape.gradient(g_loss, generator.trainable_variables)
    optimizer_G.apply_gradients(zip(grads, generator.trainable_variables))

    return d_loss, g_loss

```

## 1. Inisialisasi dan Pembuatan Gambar Palsu

- `batch_size`: Mendapatkan ukuran batch dari `real_images`.
- `noise`: Membuat noise acak dengan dimensi `[batch_size, latent_dim]`.
- `fake_labels`: Membuat label acak untuk gambar palsu dengan nilai antara 0 dan `num_classes`.
- `fake_images`: Generator menggunakan noise dan label palsu yang digabungkan untuk menghasilkan gambar palsu.

## 2. Menggabungkan Data Nyata dan Palsu

- `combined_labels`: Menggabungkan label nyata dan palsu menjadi satu tensor.
- `combined_images`: Menggabungkan gambar nyata dan palsu menjadi satu tensor.

## 3. Menggabungkan Gambar dan Label untuk Discriminator `real_images_with_labels`:

Menggabungkan gambar nyata dan label untuk input ke discriminator.

`fake_images_with_labels`: Menggabungkan gambar palsu dan label untuk input ke

discriminator. `combined_images_with_labels`: Menggabungkan input gambar nyata dan palsu untuk pelatihan discriminator.

## 4. Pelatihan Discriminator

- `GradientTape`: Merekam operasi untuk menghitung gradien.
- `real_output` dan `fake_output`: Discriminator memberikan prediksi untuk gambar nyata dan palsu.
- `d_loss_real`: Loss untuk gambar nyata (target: 1).
- `d_loss_fake`: Loss untuk gambar palsu (target: 0).
- `d_loss`: Total loss untuk discriminator.
- `grads`: Menghitung gradien untuk parameter discriminator.
- `apply_gradients`: Memperbarui bobot discriminator dengan gradien yang dihitung.

## 5. Pelatihan Generator

- `noise`: Membuat noise acak baru untuk pelatihan generator.
- `misleading_labels`: Label target untuk gambar palsu (semua 1), karena generator ingin menipu discriminator agar menganggap gambar palsu sebagai nyata.
- `GradientTape`: Merekam operasi untuk menghitung gradien.
- `fake_images`: Generator menghasilkan gambar palsu baru.
- `fake_output`: Discriminator memberikan prediksi untuk gambar palsu yang baru dihasilkan.
- `g_loss`: Loss untuk generator, berdasarkan seberapa baik gambar palsu menipu discriminator (target: 1).
- `grads`: Menghitung gradien untuk parameter generator. `apply_gradients`: Memperbarui bobot generator dengan gradien yang dihitung

```
def display_images(generator, noise, labels, epoch, num_examples=5):
    generated_images = generator.predict(combine_noise_and_labels(noise, labels, num_classes))
    generated_images = (generated_images + 1) / 2.0 # Scaling to [0, 1]

    plt.figure(figsize=(10, 2))
    for i in range(num_examples):
        plt.subplot(1, num_examples, i + 1)
        plt.imshow(generated_images[i, :, :, 0], cmap='gray')
        plt.axis('off')
    plt.suptitle(f'Epoch {epoch}')
    plt.show()
```

Menampilkan gambar yang dihasilkan oleh generator setiap interval tertentu.

```
# Training loop
def train(dataset, epochs, save_interval=5):
    for epoch in range(epochs):
        for image_batch, label_batch in dataset:
            d_loss, g_loss = train_step(image_batch, label_batch)

        print(f'Epoch {epoch+1}, D Loss: {d_loss.numpy()}, G Loss: {g_loss.numpy()}')

        if (epoch + 1) % save_interval == 0:
            # Display gambar
            noise = np.random.normal(0, 1, (5, latent_dim))
            labels = np.random.randint(0, num_classes, 5)
            display_images(generator, noise, labels, epoch + 1)

batch_size = 64
train_dataset = tf.data.Dataset.from_tensor_slices((train_images_selected, train_labels_s
train_dataset = train_dataset.shuffle(buffer_size=1024).batch(batch_size)
```


- `tf.data.Dataset.from_tensor_slices`: Fungsi ini membuat objek `tf.data.Dataset` dari tensor yang diberikan. Ini memungkinkan dataset untuk diproses dalam bentuk batch dan diacak.
- `shuffle(buffer_size=1024)`: Mengacak dataset sebelum membaginya menjadi batch. `buffer_size` menentukan ukuran buffer untuk pengacakan. Buffer dengan ukuran 1024 berarti 1024 contoh data pertama diacak sebelum pengacakan berikutnya. Ini membantu dalam membuat data yang diumpankan ke model tidak terurut, yang penting untuk menghindari bias selama pelatihan.
- `batch(batch_size)`: Membagi dataset yang telah diacak menjadi batch dengan ukuran yang ditentukan (`batch_size`). Dalam hal ini, ukuran batch adalah 64.

```
train(train_dataset, epochs=200)
```




Epoch 1, D Loss: 0.6379744410514832, G Loss: 2.773190498352051  
 Epoch 2, D Loss: 0.7039011716842651, G Loss: 2.3246123790740967  
 Epoch 3, D Loss: 0.9562605023384094, G Loss: 3.598872184753418  
 Epoch 4, D Loss: 0.9075984358787537, G Loss: 2.6260194778442383  
 Epoch 5, D Loss: 0.8241265416145325, G Loss: 1.2992808818817139

### Epoch 5




Epoch 6, D Loss: 1.4470280408859253, G Loss: 0.8378258943557739  
 Epoch 7, D Loss: 1.0839991569519043, G Loss: 1.8814704418182373  
 Epoch 8, D Loss: 0.9319779872894287, G Loss: 1.7119733095169067  
 Epoch 9, D Loss: 1.1907644271850586, G Loss: 1.2798714637756348  
 Epoch 10, D Loss: 1.0478278398513794, G Loss: 1.2268486022949219

### Epoch 10




Epoch 11, D Loss: 1.1671298742294312, G Loss: 1.976697564125061  
 Epoch 12, D Loss: 1.029853105545044, G Loss: 1.4516160488128662  
 Epoch 13, D Loss: 1.2569482326507568, G Loss: 1.2011830806732178  
 Epoch 14, D Loss: 1.1325663328170776, G Loss: 1.0589072704315186  
 Epoch 15, D Loss: 1.3950886726379395, G Loss: 1.675330638885498

### Epoch 15




Epoch 16, D Loss: 1.0255435705184937, G Loss: 1.334646224975586  
 Epoch 17, D Loss: 1.1637439727783203, G Loss: 0.9344805479049683  
 Epoch 18, D Loss: 1.0528161525726318, G Loss: 1.4309734106063843  
 Epoch 19, D Loss: 1.1808151006698608, G Loss: 2.108391284942627  
 Epoch 20, D Loss: 1.0005759000778198, G Loss: 1.0065886974334717

### Epoch 20




Epoch 21, D Loss: 1.1873269081115723, G Loss: 0.9366840124130249  
 Epoch 22, D Loss: 1.1841130256652832, G Loss: 1.6935462951660156  
 Epoch 23, D Loss: 1.3274980783462524, G Loss: 1.4008575677871704  
 Epoch 24, D Loss: 1.2617812156677246, G Loss: 1.355879545211792  
 Epoch 25, D Loss: 1.2131688594818115, G Loss: 0.9640976190567017

## Epoch 25




Epoch 26, D Loss: 1.143887996673584, G Loss: 1.2020738124847412  
 Epoch 27, D Loss: 1.1996828317642212, G Loss: 1.056776762008667  
 Epoch 28, D Loss: 1.3641676902770996, G Loss: 2.0710203647613525  
 Epoch 29, D Loss: 1.0328741073608398, G Loss: 1.661678671836853  
 Epoch 30, D Loss: 1.1236648559570312, G Loss: 1.3705518245697021

## Epoch 30




Epoch 31, D Loss: 1.1395567655563354, G Loss: 1.3887290954589844  
 Epoch 32, D Loss: 1.0912940502166748, G Loss: 1.1952505111694336  
 Epoch 33, D Loss: 1.1106579303741455, G Loss: 1.3472435474395752  
 Epoch 34, D Loss: 1.242485761642456, G Loss: 1.5615272521972656  
 Epoch 35, D Loss: 1.1867974996566772, G Loss: 1.1595933437347412

## Epoch 35



Epoch 36, D Loss: 1.0774281024932861, G Loss: 0.9695285558700562  
 Epoch 37, D Loss: 1.30208158493042, G Loss: 0.7594386339187622  
 Epoch 38, D Loss: 1.165123701095581, G Loss: 0.9940754771232605  
 Epoch 39, D Loss: 1.0247302055358887, G Loss: 0.8120534420013428  
 Epoch 40, D Loss: 1.1628785133361816, G Loss: 0.8637827038764954

## Epoch 40



Epoch 41, D Loss: 1.1466606855392456, G Loss: 1.0108760595321655  
 Epoch 42, D Loss: 1.1945319175720215, G Loss: 1.1424000263214111  
 Epoch 43, D Loss: 1.334396243095398, G Loss: 1.5083439350128174  
 Epoch 44, D Loss: 1.2104566097259521, G Loss: 1.3766069412231445  
 Epoch 45, D Loss: 1.1194721460342407, G Loss: 1.00420081615448






## Epoch 45









Epoch 46, D Loss: 1.2132549285888672, G Loss: 1.0506837368011475  
 Epoch 47, D Loss: 1.3174844980239868, G Loss: 0.9817925691604614  
 Epoch 48, D Loss: 1.2471914291381836, G Loss: 0.9041053652763367  
 Epoch 49, D Loss: 1.131304144859314, G Loss: 1.707697868347168  
 Epoch 50, D Loss: 1.1564579010009766, G Loss: 1.3317604064941406

### Epoch 50








Epoch 51, D Loss: 1.2627677917480469, G Loss: 0.6468290090560913  
 Epoch 52, D Loss: 1.1130768060684204, G Loss: 1.415946364402771  
 Epoch 53, D Loss: 1.1417545080184937, G Loss: 1.0325199365615845  
 Epoch 54, D Loss: 1.1965391635894775, G Loss: 1.6263376474380493  
 Epoch 55, D Loss: 1.102165937423706, G Loss: 1.0616941452026367

### Epoch 55








Epoch 56, D Loss: 1.1399471759796143, G Loss: 1.1899523735046387  
 Epoch 57, D Loss: 1.1712663173675537, G Loss: 0.9252578616142273  
 Epoch 58, D Loss: 1.0641043186187744, G Loss: 1.0847355127334595  
 Epoch 59, D Loss: 1.0402849912643433, G Loss: 1.5086796283721924  
 Epoch 60, D Loss: 1.2264983654022217, G Loss: 0.9273688793182373

### Epoch 60



Epoch 61, D Loss: 1.0241621732711792, G Loss: 1.5494534969329834  
 Epoch 62, D Loss: 1.0787959098815918, G Loss: 1.3031927347183228  
 Epoch 63, D Loss: 1.2038772106170654, G Loss: 1.1666584014892578  
 Epoch 64, D Loss: 1.1208375692367554, G Loss: 1.0278021097183228  
 Epoch 65, D Loss: 1.3431942462921143, G Loss: 0.7361609935760498

### Epoch 65




Epoch 66, D Loss: 1.1245524883270264, G Loss: 0.8201647996902466  
 Epoch 67, D Loss: 1.2989470958709717, G Loss: 1.4926238059997559  
 Epoch 68, D Loss: 1.1786290407180786, G Loss: 0.9151973724365234

Epoch 69, D Loss: 1.2714180946350098, G Loss: 1.4033876657485962

Epoch 70, D Loss: 1.141806721687317, G Loss: 1.0307731628417969

### Epoch 70



Epoch 71, D Loss: 1.2783334255218506, G Loss: 0.7170687913894653


Epoch 72, D Loss: 1.2068597078323364, G Loss: 0.990814208984375

Epoch 73, D Loss: 0.954565167427063, G Loss: 1.587419867515564

Epoch 74, D Loss: 1.0389280319213867, G Loss: 1.064132809638977

Epoch 75, D Loss: 1.1799795627593994, G Loss: 1.33670973777771

### Epoch 75



Epoch 76, D Loss: 0.9193814396858215, G Loss: 1.2434980869293213


Epoch 77, D Loss: 0.8987641334533691, G Loss: 1.344350814819336

Epoch 78, D Loss: 1.0522278547286987, G Loss: 1.1986360549926758

Epoch 79, D Loss: 1.0884101390838623, G Loss: 1.0858570337295532

Epoch 80, D Loss: 1.071283221244812, G Loss: 1.155930519104004

### Epoch 80



Epoch 81, D Loss: 1.133074402809143, G Loss: 1.306839108467102

Epoch 82, D Loss: 1.0684698820114136, G Loss: 1.2906138896942139

Epoch 83, D Loss: 1.114980936050415, G Loss: 1.0510250329971313

Epoch 84, D Loss: 1.115537166595459, G Loss: 1.1097311973571777

Epoch 85, D Loss: 1.090750813484192, G Loss: 1.6779544353485107

### Epoch 85



Epoch 86, D Loss: 1.1868668794631958, G Loss: 1.3522298336029053

Epoch 87, D Loss: 0.8926821351051331, G Loss: 1.2497408390045166

Epoch 88, D Loss: 0.9606360197067261, G Loss: 1.4493404626846313

Epoch 89, D Loss: 1.0634506940841675, G Loss: 1.6520256996154785

Epoch 90, D Loss: 1.277190923690796, G Loss: 1.1514337062835693

### Epoch 90







Epoch 91, D Loss: 1.2379473447799683, G Loss: 1.2765833139419556





Epoch 92, D Loss: 1.1627312898635864, G Loss: 1.0835716724395752

Epoch 93, D Loss: 0.9798874855041504, G Loss: 1.170569658279419

Epoch 94, D Loss: 1.1471644639968872, G Loss: 1.246891975402832

Epoch 95, D Loss: 0.9490104913711548, G Loss: 1.6300108432769775

### Epoch 95



Epoch 96, D Loss: 0.9310628175735474, G Loss: 1.2238422632217407





Epoch 97, D Loss: 0.8758749961853027, G Loss: 1.557909369468689

Epoch 98, D Loss: 0.9921330213546753, G Loss: 1.2358603477478027

Epoch 99, D Loss: 0.973385214805603, G Loss: 1.4089778661727905

Epoch 100, D Loss: 1.0522277355194092, G Loss: 0.9606537818908691

### Epoch 100



Epoch 101, D Loss: 0.8870193362236023, G Loss: 1.4594520330429077






Epoch 102, D Loss: 0.9380271434783936, G Loss: 1.2430534362792969

Epoch 103, D Loss: 1.0400558710098267, G Loss: 1.366645097732544

Epoch 104, D Loss: 1.0396465063095093, G Loss: 0.8170974850654602

Epoch 105, D Loss: 0.9607146978378296, G Loss: 1.5122106075286865

### Epoch 105



Epoch 106, D Loss: 1.0961471796035767, G Loss: 1.6766996383666992





Epoch 107, D Loss: 1.1351454257965088, G Loss: 1.2728444337844849

Epoch 108, D Loss: 0.764765739440918, G Loss: 1.3570793867111206

Epoch 109, D Loss: 1.238560438156128, G Loss: 1.3503024578094482

Epoch 110, D Loss: 0.9323263168334961, G Loss: 2.2183191776275635


### Epoch 110



Epoch 111, D Loss: 0.829607367515564, G Loss: 1.605949878692627


Epoch 112, D Loss: 1.1063917875289917, G Loss: 1.426284670829773  
 Epoch 113, D Loss: 0.9811052083969116, G Loss: 1.2870920896530151  
 Epoch 114, D Loss: 0.9619962573051453, G Loss: 1.4086456298828125  
 Epoch 115, D Loss: 0.810722291469574, G Loss: 1.9282331466674805

## Epoch 115




Epoch 116, D Loss: 0.6041505336761475, G Loss: 1.6322009563446045  
 Epoch 117, D Loss: 1.1446967124938965, G Loss: 1.3442442417144775  
 Epoch 118, D Loss: 0.8860812187194824, G Loss: 1.2692756652832031  
 Epoch 119, D Loss: 1.1033461093902588, G Loss: 1.145727515220642  
 Epoch 120, D Loss: 0.9944016933441162, G Loss: 1.3413811922073364

## Epoch 120




Epoch 121, D Loss: 0.8547763824462891, G Loss: 1.4496934413909912  
 Epoch 122, D Loss: 0.940322756767273, G Loss: 1.7981858253479004  
 Epoch 123, D Loss: 0.9467902183532715, G Loss: 1.9594993591308594  
 Epoch 124, D Loss: 0.8040366172790527, G Loss: 1.950905680656433  
 Epoch 125, D Loss: 0.7559592127799988, G Loss: 1.9044275283813477

## Epoch 125





Epoch 126, D Loss: 0.8479950428009033, G Loss: 2.813845157623291  
 Epoch 127, D Loss: 0.6494777798652649, G Loss: 2.0759689807891846  
 Epoch 128, D Loss: 0.8013457655906677, G Loss: 1.8322296142578125  
 Epoch 129, D Loss: 0.684378445148468, G Loss: 2.066913366317749  
 Epoch 130, D Loss: 0.8455355167388916, G Loss: 1.7727971076965332

## Epoch 130








Epoch 131, D Loss: 0.9890083074569702, G Loss: 3.005974769592285  
 Epoch 132, D Loss: 0.8736745119094849, G Loss: 2.0856213569641113  
 Epoch 133, D Loss: 0.8691834211349487, G Loss: 1.582437515258789  
 Epoch 134, D Loss: 0.8795952796936035, G Loss: 2.03226900100708  
 Epoch 135, D Loss: 0.7473081350326538, G Loss: 1.8586267232894897

## Epoch 135







Epoch 136, D Loss: 1.4141520261764526, G Loss: 1.070473074913025  
 Epoch 137, D Loss: 1.1394903659820557, G Loss: 1.916089653968811  
 Epoch 138, D Loss: 0.7048899531364441, G Loss: 1.2807199954986572  
 Epoch 139, D Loss: 0.8249019384384155, G Loss: 2.3048157691955566  
 Epoch 140, D Loss: 0.8402763605117798, G Loss: 1.3522920608520508

### Epoch 140








Epoch 141, D Loss: 0.8433606028556824, G Loss: 1.7082734107971191  
 Epoch 142, D Loss: 0.8361867666244507, G Loss: 1.7640184164047241  
 Epoch 143, D Loss: 0.8571668863296509, G Loss: 1.7912788391113281  
 Epoch 144, D Loss: 1.0107260942459106, G Loss: 2.518843412399292  
 Epoch 145, D Loss: 0.8465802669525146, G Loss: 1.6937580108642578

### Epoch 145




Epoch 146, D Loss: 0.9435883164405823, G Loss: 2.924856185913086  
 Epoch 147, D Loss: 0.856818675994873, G Loss: 1.5993921756744385  
 Epoch 148, D Loss: 0.7122563123703003, G Loss: 2.4076757431030273  
 Epoch 149, D Loss: 0.7362507581710815, G Loss: 1.8854761123657227  
 Epoch 150, D Loss: 0.8260788321495056, G Loss: 2.067689895629883

### Epoch 150




Epoch 151, D Loss: 0.5453122854232788, G Loss: 2.5949811935424805  
 Epoch 152, D Loss: 0.7829311490058899, G Loss: 1.3785158395767212  
 Epoch 153, D Loss: 0.6297023296356201, G Loss: 1.8995914459228516  
 Epoch 154, D Loss: 0.9157934784889221, G Loss: 3.0592145919799805  
 Epoch 155, D Loss: 0.6880265474319458, G Loss: 1.1675434112548828

### Epoch 155




Epoch 156, D Loss: 0.6508277654647827, G Loss: 1.557481050491333  
 Epoch 157, D Loss: 0.6735657453536987, G Loss: 2.098466396331787  
 Epoch 158, D Loss: 0.5979650020599365, G Loss: 2.4513626098632812  
 Epoch 159, D Loss: 0.7714601755142212, G Loss: 2.136305332183838  
 Epoch 160, D Loss: 0.6595715284347534, G Loss: 2.1814188957214355

## Epoch 160




Epoch 161, D Loss: 0.7123531699180603, G Loss: 2.2950823307037354  
 Epoch 162, D Loss: 0.5775043964385986, G Loss: 1.6526168584823608  
 Epoch 163, D Loss: 0.8604964017868042, G Loss: 2.1200029850006104  
 Epoch 164, D Loss: 0.6592075824737549, G Loss: 2.4606547355651855  
 Epoch 165, D Loss: 0.6730175018310547, G Loss: 1.548774242401123

## Epoch 165



Epoch 166, D Loss: 0.7988953590393066, G Loss: 1.9740347862243652  
 Epoch 167, D Loss: 0.522680401802063, G Loss: 2.3806345462799072  
 Epoch 168, D Loss: 0.41956380009651184, G Loss: 2.3564648628234863  
 Epoch 169, D Loss: 0.6913981437683105, G Loss: 1.466273546218872  
 Epoch 170, D Loss: 0.47808393836021423, G Loss: 2.163271903991699

## Epoch 170




Epoch 171, D Loss: 0.8454228639602661, G Loss: 2.038367986679077  
 Epoch 172, D Loss: 1.0265300273895264, G Loss: 0.9532777070999146  
 Epoch 173, D Loss: 0.669438898563385, G Loss: 2.8592276573181152  
 Epoch 174, D Loss: 0.6395463943481445, G Loss: 3.128671646118164  
 Epoch 175, D Loss: 0.5492278933525085, G Loss: 3.6507010459899902

## Epoch 175




Epoch 176, D Loss: 0.5808042287826538, G Loss: 2.376732349395752  
 Epoch 177, D Loss: 0.659735918045044, G Loss: 2.0723254680633545  
 Epoch 178, D Loss: 0.5108146667480469, G Loss: 2.1935524940490723  
 Epoch 179, D Loss: 0.5937590599060059, G Loss: 1.7056442499160767  
 Epoch 180, D Loss: 0.5562587976455688, G Loss: 2.229609966278076

## Epoch 180



Epoch 181, D Loss: 0.7411289811134338, G Loss: 2.465392589569092  
 Epoch 182, D Loss: 0.5317596197128296, G Loss: 1.8905329704284668  
 Epoch 183, D Loss: 0.6641603708267212, G Loss: 3.2552599906921387  
 Epoch 184, D Loss: 0.7985216379165649, G Loss: 1.8988702297210693  
 Epoch 185, D Loss: 0.6805570721626282, G Loss: 3.552091598510742

## Epoch 185




Epoch 186, D Loss: 0.5388699769973755, G Loss: 1.88716721534729  
 Epoch 187, D Loss: 0.5973830223083496, G Loss: 2.141084671020508  
 Epoch 188, D Loss: 0.651908814907074, G Loss: 2.442451000213623  
 Epoch 189, D Loss: 0.49484676122665405, G Loss: 2.480121612548828  
 Epoch 190, D Loss: 0.6298445463180542, G Loss: 1.4326483011245728

## Epoch 190



Epoch 191, D Loss: 0.4471851587295532, G Loss: 3.3534421920776367  
 Epoch 192, D Loss: 0.6857022047042847, G Loss: 1.9538860321044922  
 Epoch 193, D Loss: 0.3868386149406433, G Loss: 2.127563238143921  
 Epoch 194, D Loss: 0.591367244720459, G Loss: 2.5697438716888428  
 Epoch 195, D Loss: 0.4496127963066101, G Loss: 2.047267436981201

## Epoch 195



Epoch 196, D Loss: 0.939123272895813, G Loss: 3.8054001331329346  
 Epoch 197, D Loss: 0.5679357647895813, G Loss: 2.69551944732666  
 Epoch 198, D Loss: 0.3870052099227905, G Loss: 3.2891225814819336  
 Epoch 199, D Loss: 0.5080645084381104, G Loss: 1.4819045066833496  
 Epoch 200, D Loss: 0.5097808837890625, G Loss: 2.404428005218506

## Epoch 200





## ✓ FID

FID adalah metrik yang kuat untuk mengevaluasi kualitas gambar yang dihasilkan oleh model generatif. Ini mengukur jarak antara distribusi fitur gambar nyata dan gambar yang dihasilkan, dengan mempertimbangkan perbedaan mean dan kovariansi dari distribusi tersebut. Nilai FID yang lebih rendah menunjukkan bahwa gambar yang dihasilkan lebih mirip dengan gambar nyata.

## ✓ FID (berdasarkan vektor piksel)

```

import numpy as np
from scipy.linalg import sqrtm

def compute_fid(real_imgs, fake_imgs):
    # Flatten image ke vektor
    real_imgs_flat = real_imgs.reshape((real_imgs.shape[0], -1))
    fake_imgs_flat = fake_imgs.reshape((fake_imgs.shape[0], -1))

    mean_real = np.mean(real_imgs_flat, axis=0)
    cov_real = np.cov(real_imgs_flat, rowvar=False)
    mean_fake = np.mean(fake_imgs_flat, axis=0)
    cov_fake = np.cov(fake_imgs_flat, rowvar=False)

    mean_diff_squared = np.sum((mean_real - mean_fake) ** 2.0)
    cov_mean_sqrt = sqrtm(cov_real.dot(cov_fake))

    # Handling imaginary valuess
    if np.iscomplexobj(cov_mean_sqrt):
        cov_mean_sqrt = cov_mean_sqrt.real

    fid_value = mean_diff_squared + np.trace(cov_real + cov_fake - 2.0 * cov_mean_sqrt)
    return fid_value

noise_vector = np.random.normal(0, 1, (test_images_selected.shape[0], latent_dim))
fake_labels = test_labels_selected
fake_images = generator.predict(combine_noise_and_labels(noise_vector, fake_labels, num_c

# Menghitung nilai FID
fid_score = compute_fid(test_images_selected, fake_images)
print(f'FID: {fid_score}')

```

 FID: 9.885926466425724

## ✓ FID (berdasarkan fitur pre-trained model InceptionV3)



```
def compute_fid_2(real_features, fake_features):
    mean_real = np.mean(real_features, axis=0)
    cov_real = np.cov(real_features, rowvar=False)
    mean_fake = np.mean(fake_features, axis=0)
    cov_fake = np.cov(fake_features, rowvar=False)

    mean_diff_squared = np.sum((mean_real - mean_fake) ** 2.0)
    cov_mean_sqrt = sqrtm(cov_real.dot(cov_fake))

    # Handling imaginary values
    if np.iscomplexobj(cov_mean_sqrt):
        cov_mean_sqrt = cov_mean_sqrt.real

    fid_value = mean_diff_squared + np.trace(cov_real + cov_fake - 2.0 * cov_mean_sqrt)
    return fid_value

# Mengubah gambar grayscale menjadi RGB
def to_rgb(images):
    return np.repeat(images, 3, axis=-1)

# Mengubah ukuran gambar ke ukuran input InceptionV3 dan mengubah menjadi RGB dalam batch
def get_features(images, batch_size=32):
    features = []
    for i in range(0, len(images), batch_size):
        batch = images[i:i + batch_size]
        batch_resized = tf.image.resize(batch, (299, 299))
        batch_rgb = to_rgb(batch_resized)
        batch_preprocessed = preprocess_input(batch_rgb)
        batch_features = inception_model.predict(batch_preprocessed)
        features.append(batch_features)
    return np.concatenate(features, axis=0)

# Load InceptionV3 model tanpa top layer
inception_model = InceptionV3(include_top=False, pooling='avg', input_shape=(299, 299, 3))

real_features = get_features(test_images_selected)
fake_features = get_features(fake_images)

fid_score_2 = compute_fid_2(real_features, fake_features)
print(f'FID: {fid_score_2}')
```



```

1/1 [=====] - 0s 53ms/step
1/1 [=====] - 0s 53ms/step
1/1 [=====] - 0s 55ms/step
1/1 [=====] - 0s 75ms/step
1/1 [=====] - 0s 72ms/step
1/1 [=====] - 0s 72ms/step
1/1 [=====] - 0s 75ms/step
1/1 [=====] - 0s 92ms/step
1/1 [=====] - 0s 77ms/step
1/1 [=====] - 0s 78ms/step
1/1 [=====] - 0s 51ms/step
1/1 [=====] - 0s 53ms/step
1/1 [=====] - 4s 4s/step
1/1 [=====] - 0s 52ms/step
1/1 [=====] - 0s 54ms/step
1/1 [=====] - 0s 52ms/step
1/1 [=====] - 0s 56ms/step
1/1 [=====] - 0s 67ms/step
1/1 [=====] - 0s 56ms/step
1/1 [=====] - 0s 54ms/step
1/1 [=====] - 0s 54ms/step
1/1 [=====] - 0s 55ms/step
1/1 [=====] - 0s 52ms/step
1/1 [=====] - 0s 71ms/step
1/1 [=====] - 0s 76ms/step
1/1 [=====] - 0s 78ms/step
1/1 [=====] - 0s 81ms/step
1/1 [=====] - 0s 77ms/step
1/1 [=====] - 0s 90ms/step
1/1 [=====] - 0s 52ms/step
1/1 [=====] - 0s 52ms/step
1/1 [=====] - 0s 52ms/step
1/1 [=====] - 0s 54ms/step
1/1 [=====] - 0s 51ms/step
1/1 [=====] - 0s 53ms/step
1/1 [=====] - 0s 53ms/step
1/1 [=====] - 0s 70ms/step
1/1 [=====] - 0s 52ms/step
1/1 [=====] - 0s 53ms/step
1/1 [=====] - 0s 52ms/step
1/1 [=====] - 0s 57ms/step
1/1 [=====] - 0s 52ms/step
1/1 [=====] - 0s 52ms/step
1/1 [=====] - 0s 59ms/step

```

## ✓ EXPLANATION


### Interpretasi Nilai FID:

- FID (Fréchet Inception Distance) mengukur kesamaan antara dua set gambar. Nilai lebih rendah berarti gambar palsu lebih mirip dengan gambar nyata.
- Vektor Piksel: FID sebesar 9.885926466425724 menunjukkan distribusi piksel gambar palsu cukup mirip dengan gambar nyata, tetapi ini mungkin tidak mencerminkan kesamaan visual sepenuhnya.


- InceptionV3: FID sebesar 0.19446185529309828 menunjukkan gambar palsu sangat mirip dengan gambar nyata dalam hal distribusi fitur tingkat tinggi. Ini menunjukkan generator menghasilkan gambar yang hampir tidak dapat dibedakan dari gambar nyata.
- Perbandingan: FID di bawah 10 dianggap baik. Nilai FID yang jauh lebih rendah dengan InceptionV3 menunjukkan perbandingan menggunakan fitur tingkat tinggi memberikan gambaran lebih akurat tentang kesamaan visual.

## ✓ Screen Shoot Perbandingan (ACAK)

Di Epoch ke-5:



Di Epoch ke-200:



Real-Image



1. Baris Pertama (Epoch 5):

- Gambar pada baris pertama menunjukkan hasil dari generator setelah 5 epoch pelatihan.
- Gambar-gambar ini masih sangat kabur dan tidak jelas. Bentuk dasar dari objek seperti T-shirt/top dan Trouser dapat dilihat, tetapi detail dan kejelasan masih sangat kurang.
- Ini menunjukkan bahwa pada tahap awal pelatihan, generator masih belajar menghasilkan pola dasar dari gambar yang diinginkan.

## 2. Baris Kedua (Epoch 200):

- Gambar pada baris kedua menunjukkan hasil dari generator setelah 100 epoch pelatihan.
- Gambar-gambar ini lebih jelas dibandingkan dengan hasil setelah 5 epoch. Bentuk dari T-shirt/top dan Trouser lebih terdefinisi, dan beberapa detail mulai muncul.
- Ini menunjukkan kemajuan yang signifikan dalam kemampuan generator untuk menghasilkan gambar yang lebih realistis seiring dengan bertambahnya jumlah epoch pelatihan.

## 3. Baris Ketiga (Gambar Asli):

- Gambar pada baris ketiga adalah gambar asli dari dataset, dengan label yang sesuai.
- Gambar-gambar ini sangat jelas dan terdefinisi dengan baik, menunjukkan T-shirt/top dan Trouser dengan detail yang sempurna.
- Gambar asli ini digunakan oleh discriminator untuk membedakan antara gambar nyata dan gambar palsu yang dihasilkan oleh generator.

# ✓ KESIMPULAN

## 1. Kemajuan Pelatihan:

- Dari Epoch 1 sampai 200, terlihat jelas bahwa generator menjadi lebih baik dalam menghasilkan gambar yang lebih realistis seiring dengan bertambahnya jumlah epoch pelatihan. Ini menunjukkan bahwa model GAN belajar dan meningkatkan kualitas hasilnya seiring waktu.

## 2. Perbandingan dengan Gambar Asli:

- Gambar pada baris ketiga berfungsi sebagai referensi atau target akhir yang diinginkan. Meskipun hasil setelah 200 epoch masih belum sempurna seperti gambar asli, terlihat ada kemajuan yang signifikan dari epoch 5 ke epoch 200.

## 3. Evaluasi Kualitas:

- Dengan menggunakan Fréchet Inception Distance (FID), didapatkan nilai yang mengukur seberapa mirip distribusi gambar palsu dengan gambar asli.

- Nilai FID berdasarkan vektor piksel adalah 9.885926466425724, menunjukkan distribusi piksel gambar palsu cukup mirip dengan gambar nyata, tetapi mungkin tidak mencerminkan kesamaan visual sepenuhnya.
- Nilai FID berdasarkan fitur InceptionV3 adalah 0.19446185529309828, menunjukkan gambar palsu sangat mirip dengan gambar nyata dalam hal distribusi fitur tingkat tinggi. Ini menunjukkan bahwa generator berhasil menghasilkan gambar yang hampir tidak dapat dibedakan dari gambar nyata.

Gambar ini dengan jelas menunjukkan bagaimana model GAN belajar dan meningkatkan kemampuannya dalam menghasilkan gambar yang realistis dengan bertambahnya jumlah epoch pelatihan. Ini memberikan wawasan visual yang baik tentang proses pelatihan model dan kesamaan visual antara gambar palsu dan nyata berdasarkan metrik FID.

FOLDER VIDEO:

[https://drive.google.com/drive/folders/1xqjdupi1iiNEGL7FXW0IVlbF4yBO-Yap?usp=drive\\_link](https://drive.google.com/drive/folders/1xqjdupi1iiNEGL7FXW0IVlbF4yBO-Yap?usp=drive_link)

LINK CODE NO 1 (COLLAB):

<https://colab.research.google.com/drive/1-mf7uwgtoidDISb9HvNN6yhmnyD9Uent#scrollTo=3DJpZU9B1xMo>

LINK CODE NO 2 (COLLAB):

[https://colab.research.google.com/drive/1m-zM99EvRIIzz1Pmh\\_eXewD0yLtoi9f0#scrollTo=LQjAJ3GZ8S1w](https://colab.research.google.com/drive/1m-zM99EvRIIzz1Pmh_eXewD0yLtoi9f0#scrollTo=LQjAJ3GZ8S1w)

LINK CODE NO 3 (COLLAB):

[https://colab.research.google.com/drive/1AqZXrCweHM1jTqAxYJnP7B-zHojKVQ1I#scrollTo=Rh5\\_uFY1yG9H](https://colab.research.google.com/drive/1AqZXrCweHM1jTqAxYJnP7B-zHojKVQ1I#scrollTo=Rh5_uFY1yG9H)

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.

Start coding or [generate](#) with AI.